




# IoT Cihazlar için Performans Araştırması

# IoT Cihazlarda Latency ve Throughput

Pratik hedef, kamera tabanlı IoT (vision) için:

30 FPS gerçek zaman demek, her frame için toplam ~33 ms civarında olması demek.

60 FPS hedefleniyorsa, frame başına ~16.7 ms olur (daha sıkı).

**Bu 33 ms sadece model inference değil, kamera capture, preprocess, postprocess, (varsa) network, queueing gibi her şeyi kapsıyor.**

# Latency Standartları

- Ultra düşük gecikme ( $< 30$  ms): Otonom dronlar, yüksek frekanslı endüstriyel otomasyon ve cerrahi robotik sistemler için gereklidir.
- Gerçek zamanlı gecikme ( $< 100$  ms): Bilgisayarlı görü, akıllı kameralar ve etkileşimli AR uygulamalarında “algılanan gerçek zaman” için standart hedef olarak kabul edilir.
- Tolere edilebilir gecikme (150 ms – 250 ms): Akıllı tarım izleme veya kritik olmayan anomali tespiti gibi zaman hassasiyeti daha düşük görevler için genellikle yeterlidir.

# Throughput Standartları

- Düşük seviye görevler: Temel gözetim uygulamaları için 5–10 FPS (saniyedeki kare sayısı) çoğu zaman yeterli kabul edilir.
- Üst seviye IoT: Akıcı video analitiği ve robotik uygulamalarında 30–60 FPS genellikle hedeflenen ölçüttür.

# Farklı Kategorilerde:


- **Vision sensörleri:** yüksek throughput, düşük frame latency (30+ FPS, frame başına  $\leq 33$  ms)
- **Endüstriyel kontrol:** deterministik, çok düşük latency öncelikli (Güvenlik için genelde  $<100$  ms yanıt)
- **Smart home:** kullanıcı hissi için interaktif latency (çoğunlukla  $<100$  ms hedeflenir)
- **Medikal:** güvenlik için tutarlı, düşük latency ve yüksek güvenilirlik (Remote robotic surgery gibi uç örneklerde “birkaç ms” seviyeleri konuşulur)






# Latency, Throughput trade-off

- Batch büyüdükçe throughput artar, fakat tek örnek latency artar
- Edge gerçek zamanlı işlerde çoğunlukla batch=1
- Sadece throughput öncelikliyse küçük batch'ler (2–8) denenebilir, ölçerek karar verilir





**IoT  
Cihazlar için  
Hangi GPU,  
Batch size,  
Model**

## TensorRT

```
PyTorch Latency: 27.914714336395264 ms  
PyTorch FPS: 35.82340080393364  
ONNX Runtime Latency: 2.971470355987549 ms  
ONNX Runtime FPS: 336.5337291637414  
TensorRT FP16 Latency: 0.38864803314208984 ms  
TensorRT FP16 FPS: 2573.022155587237
```

---



FP16

=== FINAL RESULTS ===

| Engine | Latency (ms) | Throughput (FPS) |
|--------|--------------|------------------|
| FP32   | 0.4295       | 2328.08          |
| FP16   | 0.3039       | 3290.60          |

## TensorRT + Custom Kernel Plugin

### Latency

PyTorch FP16 depthwise conv: 0.018766 ms

Custom CUDA kernel: 0.009842 ms

Speedup (PyTorch / Custom): 1.91x

### Throughput

C=16, H=W=112 | PT throughput=64379/s | CU throughput=104613/s | speedup=1.62x  
C=32, H=W=56 | PT throughput=54448/s | CU throughput=102617/s | speedup=1.88x  
C=64, H=W=28 | PT throughput=52405/s | CU throughput=104384/s | speedup=1.99x

Pointwise PT latency: 0.0372 ms  
Pointwise CU latency: 0.0235 ms  
PT throughput: 26918 samples/s  
CU throughput: 42516 samples/s  
Speedup: 1.58x

## NVIDIA L4

=== FINAL RESULTS ===

| Engine | Latency (ms) | Throughput (FPS) |
|--------|--------------|------------------|
| FP32   | 0.3714       | 2692.36          |
| FP16   | 0.2992       | 3342.45          |

A100

=== FINAL RESULTS ===

| Engine | Latency (ms) | Throughput (FPS) |
|--------|--------------|------------------|
| FP32   | 0.2857       | 3500.44          |
| FP16   | 0.2577       | 3879.74          |

L4

PyTorch Latency: 22.01592445373535 ms

PyTorch FPS: 45.42166748897679

ONNX Runtime Latency: 2.53363037109375 ms

ONNX Runtime FPS: 394.6905639469056

TensorRT FP16 Latency: 0.34925031661987305 ms

TensorRT FP16 FPS: 2863.275858067176

A100

PyTorch Latency: 21.297357082366943 ms

PyTorch FPS: 46.954182912580535

ONNX Runtime Latency: 3.946469783782959 ms

ONNX Runtime FPS: 253.39101900874866

TensorRT FP16 Latency: 0.23839330673217773 ms

TensorRT FP16 FPS: 4194.748643356195

L4

PyTorch Latency: 24.031813144683838 ms

PyTorch FPS: 41.611508627313604

ONNX Runtime Latency: 3.9933128356933594 ms

ONNX Runtime FPS: 250.41864766058828

TensorRT FP16 Latency: 0.6218981742858887 ms

TensorRT FP16 FPS: 1607.9802793251113

T4

=== FINAL RESULTS ===

| Engine | Latency (ms) | Throughput (FPS) |
|--------|--------------|------------------|
| FP32   | 0.6553       | 1526.03          |
| FP16   | 0.3447       | 2900.84          |

T4

| Bileşen    | Seçim                           | Gerekçe                                                                                                                                                                                      |
|------------|---------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| GPU        | NVIDIA L4                       | A100 daha hızlı olsa da, L4 özellikle edge veya inference yoğun iş yükleri için tasarlanmıştır ve watt başına yüksek performans sunar.                                                       |
| Batch Size | 1                               | IoT senaryolarında yanıt süresini, yani latency'yi en aza indirmek için kritiktir. Sonuçlarımıza göre, L4 ve A100 üzerinde Batch 1 için 0.23 ms ile 0.34 ms arasında latency göstermektedir. |
| Precision  | FP16                            | Test edilen tüm GPU'larda latency ve throughput açısından FP32'ye kıyasla tutarlı biçimde daha iyi performans göstermektedir, hızlanma bazı durumlarda 2 kata kadar çıkmaktadır.             |
| Engine     | TensorRT + Custom Kernel Plugin | Özel depthwise kerneli 2.07 kat, pointwise kerneli ise 2.61 kat hızlanma sağlayarak standart PyTorch FP16 uygulamasını belirgin şekilde geride bırakmaktadır.                                |



# Recommended IoT Deployment Sets



## Set 1: Real-Time IoT (Single Stream)



- **GPU:** L4
- **Batch:** 1
- **Precision:** FP16
- **Runtime:** TensorRT FP16
- **Option:**
  - Custom plugin layers iff profiled ops persist



## Set 2: Edge Gateway (Multi-Stream)



- **GPU:** L4
- **Batch:** 4/8/16  
Based on latency dught balance
- **Precision:** FP16, INT8  
(future investigation) 🖱️
- **Runtime:** TensorRT FP16



## Set 3: Low-Cost / Legacy Edge



- **GPU:** T4
- **Batch:** 1 or 4
- **Precision:** FP16
- **Runtime:** TensorRT FP16

# Referenslar

Latency&Throughput

Latency&Throughput

VideoSensors

IndustrialControllers

IndustrialController2

SmartDevices