



Large Language Models İçin Optimizasyon

BERT Modeli

Google tarafından geliştirilen, **Transformer** tabanlı bir **doğal dil işleme** (NLP) modelidir.

- Metni **iki yönlü (bidirectional)** olarak anlar
- Cümledeki **her kelimeyi, tüm bağlamı** kullanarak temsil eder
- Metin üretmekten ziyade **metni anlamaya** odaklanır




Bidirectional Encoder Representations from Transformers

Nasıl Çalışır?

- **Encoder-only Transformer** mimarisi kullanır.
- **Self-attention** sayesinde:
 - Her kelime, cümlenin tamamını dikkate alır.
- Eğitim sırasında:
 - Cümledeki bazı kelimeler **maskelenir**.
 - Model bu kelimeleri **tahmin etmeye** çalışır (Masked Language Modeling)

Örnek: “TensorRT optimization is [MASK]”

→ **Model:** powerful




Encoder ne yapar?

- Girdi olarak tam bir cümleyi alır.
- Cümlelerin anlamını temsil eden **vektörler** üretir.
- Çıkış, yeni bir metin değil, anlamsal temsildir.


Self-Attention ne demek?

Self-attention, bir kelimenin anlamını belirlerken aynı cümledeki diğer tüm kelimelere bakabilmesi demektir.





BERT neden önemlidir?

- Kelimeleri sayısal vektörlere dönüştürür
- Metin verisinin makine öğrenmesi modelleri tarafından kullanılmasını sağlar
- Metin verisini, diğer veri türleriyle birlikte tahmin yapmak için kullanılabilir hale getirir
- Doğal dilin bağlamını koruyan güçlü temsiller üretir




Kullanım Alanları

- Film yorumlarının olumlu veya olumsuz olduğunu belirlemek
- Chatbotların doğru cevaplar vermesini sağlamak
- E-posta yazımında metin tahmini yapmak
- Uzun hukuki metinleri hızlıca özetlemek
- Kelimelerin bağlama göre anlamını ayırt etmek




Transformer



Encoder


Decoder

GPT*



Decoder-only

BERT*




Encoder-only

*Illustrative example, exact model architecture may vary slightly


Örneklerle BERT Algoritması

Kaynak



BERT, kullanıcı niyetini bağlamdan doğru anlayarak, alakasız haberler yerine doğrudan elçilik ve konsolosluk gibi en uygun arama sonuçlarını sunmayı sağlar.

Kaynak



BERT, arama sorgusundaki gerçek niyeti doğru anlayarak genel ve alakasız içerikler yerine kullanıcının sorusuna doğrudan cevap veren sonuçları öne çıkarır.

Kaynak



height of the landmark in paris



All



News



Images



Maps



Shopping



More



Settings



Tools

About 26,700,000 results (0.92 seconds)

The tallest structure in the City of **Paris** and the Île de France remains the Eiffel Tower in the 7th arrondissement, 300 meters high (or 324 m including the broadcasting antenna at its top), completed in 1889 as the gateway to the 1889 **Paris** Universal Exposition.




[List of tallest buildings and structures in the Paris region ...](https://en.wikipedia.org/wiki/List_of_tallest_buildings_and_structures_in_Paris)


[https://en.wikipedia.org › wiki › List_of_tallest_buildings_and_structures_in...](https://en.wikipedia.org/wiki/List_of_tallest_buildings_and_structures_in_Paris)

BERT, sorguda açıkça belirtilmese bile bağlamı doğru analiz ederek, kullanıcının aradığı bilgiyi featured snippet olarak doğrudan sunabilir.

Featured snippet, Google'ın bir arama sonucuna doğrudan ve kısa bir cevap vermek için, bir web sayfasından seçtiği içeriği sayfanın en üstünde göstermesidir.



Google Colab'te A100'de BERT



Model	#params	Language
<u>bert-base-uncased</u>	110M	English
<u>bert-large-uncased</u>	340M	English
<u>bert-base-cased</u>	110M	English
<u>bert-large-cased</u>	340M	English
<u>bert-base-chinese</u>	110M	Chinese
<u>bert-base-multilingual-cased</u>	110M	Multiple
<u>bert-large-uncased-whole-word-masking</u>	340M	English
<u>bert-large-cased-whole-word-masking</u>	340M	English

Wed Dec 24 14:10:45 2025

NVIDIA-SMI 550.54.15			Driver Version: 550.54.15		CUDA Version: 12.4	
GPU	Name	Persistence-M	Bus-Id	Disp.A	Volatile Uncorr. ECC	
Fan	Temp	Perf	Pwr:Usage/Cap	Memory-Usage	GPU-Util	Compute M.
						MIG M.
=====						
0	NVIDIA A100-SXM4-80GB	Off	00000000:00:05.0	Off	0	
N/A	34C	P0	52W / 400W	0MiB / 81920MiB	0%	Default
						Disabled

Processes:						
GPU	GI	CI	PID	Type	Process name	GPU Memory Usage
	ID	ID				
=====						
No running processes found						

- bert-base-uncased BERT modelini ve tokenizer'ını indirip GPU'da çalıştırır.
 - Tek bir metni tokenize eder, input'u sabit uzunluğa (SEQ_LEN) pad eder.
 - Aynı input için 3 farklı backend ile inference yapıp kıyaslar:
 - PyTorch FP16
 - ONNX Runtime CUDA
 - TensorRT FP16
- Tokenizer, metni sayısal tokenlara dönüştürerek modelin metni doğru şekilde anlayabilmesini sağlar.**
- PyTorch tarafında warmup + tekrar çalıştırma ile ortalama latency ölçer.
 - PyTorch modelini ONNX'e export eder, sonra ONNX Runtime ile GPU'da çalıştırıp latency ölçer.
 - ONNX modelinden TensorRT FP16 engine oluşturur, GPU'da çalıştırıp latency ölçer.
 - Her backend için throughput (seq/s) hesaplar ve en sonda speedup oranlarını yazdırır.

PyTorch FP16 latency: 8.156 ms | Throughput: 122.6 seq/s
ONNX Runtime CUDA latency: 4.123 ms | Throughput: 242.5 seq/s
TensorRT FP16 latency: 0.700 ms | Throughput: 1428.7 seq/s

===== SPEEDUPS =====

ONNX vs PyTorch: 1.98x

TensorRT vs PyTorch: 11.65x

BERT ON A100

PyTorch FP16 latency: 8.156 ms | Throughput: 122.6 seq/s

ONNX Runtime CUDA latency: 4.123 ms | Throughput: 242.5 seq/s

TensorRT FP16 latency: 0.700 ms | Throughput: 1428.7 seq/s

MOBILENET ON A100

PyTorch Latency: 22.01592445373535 ms

PyTorch FPS: 45.42166748897679

ONNX Runtime Latency: 2.53363037109375 ms

ONNX Runtime FPS: 394.6905639469056

TensorRT FP16 Latency: 0.34925031661987305 ms

TensorRT FP16 FPS: 2863.275858067176

TensorRT optimizasyonu, hem CNN hem Transformer modellerinde latency'yi düşürerek throughput'u arttırıp A100 GPU'nun gerçek potansiyelini ortaya çıkarıyor.